

# Datenanalyse Notizen

Benjamin Dropmann

April 7, 2025

## 1 TLDR

Name	Bedeutung	Formel
Messfehler	Der Messfehler ist die abweichung vom gemessenen Wert $x_1$ zum theoretischen oder erwarteten Wert $\tilde{x}$	$e = \tilde{x} - x_1$
Probability Density Function	Dies ist eine Funktion $f$ (Probability Mass Funktion falls diskret) die die wahrscheinlichkeit $P_{a,b}(x)$ dass eine variable $x$ zwischen zwei punkte $a, b$ fällt	$P_{a,b}(x) = \int_a^b f(x)dx$
Normalverteilung	Die Normalverteilung ist eine Funktion $f$ mit variablen $\mu$ :Erwartungswert und $\sigma$ :Standardabweichung, die sehr oft die verbreitung zufälliger Datenaufnahmen spiegelt	$f(x, \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$
Binomialverteilung	Die Binomialverteilung beschreibt die wahrscheinlichkeit dass in $n$ Versuchen das ereigniss mit Wahrscheinlichkeit $P(u) = p$ genau $k$ mal vorkommt	$B(k p, n) = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$
Mittelwertfehler	Der Fehler des Mittelwerts bei einer wiederholung einer Messwiederholung auf $N$ mal, wobei $\sigma$ die Standardabweichung ist	$\Delta\mu = \frac{\sigma}{\sqrt{N}}$

## Messfehler

Messen wir einen Wert von welchen wir schon eine Theoretische einschätzung  $\tilde{x}$  haben, sei der gemessenen Wert  $x_1$  dann haben wir einen **Massfehler**  $e = \tilde{x} - x_1$ . Dieser Fehler kann systematisch (es kommt bei jeder Messung gleich vor) oder Zufällig (es war ein Zufall dass es diesmal den wert  $e$  angenommen hat, und es könnte nächstes mal irgendein Wert annehmen).

## Wiederholtes Messen

Mit einer Wiederholung des Messens, kann man dieses Zufällige Fehler minimiseren. Mit viele Messwerte kann man den **Empirischen Mittelwert**:

$$\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n$$

und die **Empirische Varianz**:

$$\Delta_x^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})^2$$

Berechnen. Die **Empirische Standardabweichung** ist ähnlich definiert:  $\Delta_x = \sqrt{\Delta_x^2}$

Wenn wir Viele Messungen haben, können wir in einem Histogramm darstellen in dem wir Bins (wertebereiche) defnieren und die Anzahl messung in jedes Bin darstellen.

## Probability Density Function

Wir können dann dieses Histogramm eine Funktion zuordnen die ungefähr diese anpasst. So eine Funktion heisst Probability Mass Funktion und hat die Eigenschaften dass:  $0 \leq P(x_n) \leq 1$  und  $\sum P(x_n) = 1$  wobei  $x_n$  eine bin ist und  $P(x_n)$  Die wahrscheinlichkeit dass eine Messung in diese Bin reinfällt. Wenn diese Funktion nicht mehr Diskret definiert ist sondern Kontinuierlich dann nennt man diese Probability Density Funktion und beugt sich zur Eigenschaften  $\int_{-\infty}^{\infty} f(x) = 1$  und

$0 \leq f(x)$  hier ist die Wahrscheinlichkeit dass  $a \leq x \leq b$  vom integral  $P(a \leq x \leq b) = \int_a^b f(x)dx$  Diese PDF hat mehrere Werte die in korrelation damit sind:

- Modus:  $x_{\text{mode}} : \left. \frac{df(x)}{dx} \right|_{x_{\text{mode}}} = 0$  ist der Wert bei dem die function ihr maximum annimt
- Median  $x_{\text{median}} : \int_{-\infty}^{x_{\text{median}}} f(x)dx = \frac{1}{2}$  ist der Wert bei welchem die Wahrscheinlichkeiten auf jeder seite dieses Punktes zu legen gleich sind
- Halbwertsbreite:  $f(a) = f(b) = \frac{1}{2}f(x_{\text{mode}}) \implies H_{\text{breite}} = b - a$  Ist die breite der Verteilung beim Halben wert des Maximalwertes.
- Erwartungswert:  $\mu = E(x) = \int_{-\infty}^{\infty} xf(x)dx$  der wert  $x$  für welches  $f(x) = x_{\text{mode}}$
- Varianz:  $\text{var}(x) = E((x - \mu)^2) = \int_{-\infty}^{\infty} (x - \mu)^2 f(x)dx$  Wie zuvor. die Standardabweichung ist einfach  $\sqrt{\text{var}(x)}$

Momente können auch definiert werden aber sind nicht sehr nützlich.

## Normalverteilung

Wenn wir Zurück zum Histogramm gehen dann ist die Funktion die diese Folgt am aller meistens eine Normalverteilung. Wenn wir viele Messungen mit einen Zufälligen Messfehler Betrachten, wird dieser Histogramm eine Normalverteilung folgen. Die Definition dieser Normalverteilung ist:

$$f(x, \mu, \sigma) = \frac{1}{\sigma\sqrt{2 \cdot \pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Wobei  $\mu$  der Erwartungswert ist und  $\sigma$  die Standardabweichung, diese Werte müssen Experimentell gefunden werden.

## Binomialverteilung

Wenn wir zwei ereignisse  $u$  und  $d$  mit wahrseheilickeiten  $P(u) = p$  und  $P(d) = 1 - p = q$  respektiv haben. Dann kann man, erstens die anzahl der unterschiedlichen Reihenfolgen von  $k$  objekten in  $n$  plätze definieren durch  $n$  "tief"  $k$

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

z.B. 5 Studente in 7 arbeitsplätze haben  $\binom{7}{5} = 21$  unterschiedliche sitzplane. Dann kommt Binomialverteilung die die Wahrscheinlichkeit beschreibt dass in  $n$  versuchen  $k$  mal den ereigniss  $u$  mit wahrseheilichkeit  $P(u) = p$  vorkommt:

$$B(k|p, n) = \binom{n}{k} p^k (1-p)^{n-k}$$

Hier beschreibt der teil  $p^k(1-p)^{n-k}$  die wahrseheilichkeit von genau eine distribution der Ereignisse. Die Poissonverteilung ist die Binomialverteilung für  $\lim_{k \rightarrow \infty}$

## Mittelwertfehler

Wenn wir eine Messung vielmals wiederholen, dann wird die standardabweichung ab einen Punkt nicht mehr viel variieren, doch mit mehr messpunkte, sind wir uns sicherer und sicherer dass unser Mittelwert korrekt ist. Deswegen ist der Fehler des Mittelwerts nicht einfach die Standardabweichung sondern durch:

$$\Delta\mu = \frac{\sigma}{\sqrt{N}}$$

## Fehlerfortpflanzung

Wenn wir experimentell was bestätigen wollen misst man meistens nicht sofort die wichtige Grösse sondern eine Andere mit deren man die wichtige grössen rechnen kann. Doch die unsicherheiten können sehr schnell schwierige beiträge zur rechnung bringen. Deswegen gibt es eine einfachere Methode die uns hilft diese Fehlerfortpflanzung abzuschätzen im fall von einer Normalverteilten PDF wo die funktion  $f$  nur von einer fehlerbehafteten Messgrösse  $x$  abhängt. Dann kann man die Taylorentwicklung des ersten Grades benutzen um folgendes Zusammenhang zu finden

$$\Delta f(x) = f(\bar{x} - \Delta x) - f(\bar{x}) = \left. \frac{\partial f}{\partial x} \right|_{\bar{x}} \Delta x$$

Wobei  $\Delta$  einen Fehler bezeichnet,  $\bar{x}$  der punkt um deren wir den Fehler berechnen. Die standardabweichung lässt sich auch derselben weise rechnen:

$$\sigma_f = \left. \frac{\partial f}{\partial x} \right|_{\bar{x}} \sigma_x$$

## Mehrdimensional Fehlerfortpflanzung

Wir können es erweitern bis zum fall wo die funktion  $f$  von mehrere Fehler behafteten Messgrössen. In diesem Fall hängt der Fehler  $\Delta f$  auch von der Kovarianz zwischen  $x$  und  $y$  die zwei Messgrössen.

$$\sigma_f^2 = (\partial_x, \partial_y) f \begin{pmatrix} \sigma_x^2 & \sigma_{xy}^2 \\ \sigma_{xy}^2 & \sigma_y^2 \end{pmatrix} \begin{pmatrix} \partial_x \\ \partial_y \end{pmatrix} f$$

Wenn die kovarianz  $\sigma_{xy} = 0$  dann ist dies einfach eine Diagonale Matrix und es wird zu summe:

$$\sigma_f^2 = \sum_{n=1}^N \left( \frac{\partial f}{\partial x_n} \right) \sigma_{x_n}^2$$

## Fouriertransform

Wir können jede Funktion auf einem beschränkte Zeitperiode als eine Summe von Trigonometrischen funktionen definieren. Wenn ich eine funktion  $x_{t_k}$  habe dann kann ich eine frequenz hier einsetzen: (in theorie ist dies ein Integral aber hier handelt es sich um diskrete daten)

$$X(f_n) = \frac{1}{N} \sum_{k=0}^{N-1} x(t_k) e^{-i2\pi f_n t_k}$$

und ich bekomme ein anteil der trigonometrischen funktionen von dieser fräquenz in der funktion.

Wie man das praktisch macht, man misst für alle frequenzen die Gleichung und dann bekommt man den anteil dieser fräquenz auf der funktion welche wir den Fouriertransform machen

## Aliasing

Man muss aufpassen wenn man eine Welle misst, wenn  $\Delta t > \frac{1}{\nu}$  dann ist unsere messung okay, man braucht also mindestens zwei messpunkte pro oszillation der Welle, sonst kann ein Fall von Aliasing passieren wo wir eine höhere fräquenz messen als was eigentilch ist.

## Gabors limit

Wenn sag ich dass eine fräquenz nicht im Transform auftaucht? Gabors limit besagt dass je langer ein signal ist in der zeit, desto besser kann die präzision der messung vom signal sein:  $\sigma_t \cdot \sigma_f \geq \frac{1}{2}$ . Wobei  $\sigma$  die auflösung der Messung ist. Daher limitiert die Messzeit  $t_{tot}$   $\sigma_t$ . Wenn man den Fouriertransform von einer funktion mit eine auflösung  $\sigma_t$ , mit eine kleinere auflösung misst, bekommt man nicht mehr information, die zwei werte sind dann auf distanzen kleine als  $\sigma_t$  korreliert und bringen nicht neue information. Zusätzlich ist die Maximale frequenz die ich messen kann ist  $f_{max} = \frac{1}{2\Delta t}$  die minimale frequenz lässt sich analog finden aber die negative Fourierwerte haben nicht mehr information als die positive